

Proposta de Projeto Final

P8 · NAS Leve com Metaheurísticas — Entrega P9 (Semana 9)

1. Equipe

Rayane Araújo, Júlia Júnior, Marcelo Soares, João Pedro e João Arthur.

2. Problema Escolhido

Problema: P8 — Neural Architecture Search (NAS) Leve

Diferencial: D3 — Otimização de Hiperparâmetros (HPO) com Optuna como terceira estratégia de busca arquitetural

Dataset: MNIST (classificação de dígitos manuscritos, 60.000 imagens de treino, 10.000 de teste, 10 classes)

O problema consiste em encontrar automaticamente arquiteturas de redes neurais convolucionais (CNNs) compactas e eficientes para a tarefa de classificação do MNIST. Em vez de projetar a arquitetura manualmente, o espaço de configurações possíveis é tratado como um espaço de busca discreto/combinatório, e três estratégias metaheurísticas são aplicadas e comparadas: Algoritmo Genético (AG), Population-Based Incremental Learning (PBIL) e Optuna (TPE — Tree-structured Parzen Estimator).

3. Justificativa

O ajuste de hiperparâmetros e a definição manual de arquiteturas de redes neurais são tarefas custosas e dependentes de experiência, representando um gargalo recorrente em projetos de Inteligência Artificial. NAS surge como resposta a esse desafio, automatizando a busca por configurações arquiteturais de alto desempenho.

A escolha do problema é motivada pela formação da equipe no Bacharelado em IA da UFG: a intersecção entre metaheurísticas e aprendizado profundo é diretamente relevante para a prática profissional e acadêmica dos integrantes. O MNIST, embora simples, permite ciclos de avaliação rápidos, viabilizando experimentos com múltiplas sementes e configurações dentro das restrições computacionais da disciplina.

A comparação entre AG, PBIL e Optuna (D3) é especialmente interessante porque representa três paradigmas distintos de busca: evolutivo baseado em população, baseado em distribuição de probabilidade e baseado em modelo probabilístico sequencial (TPE). Isso permite analisar qual paradigma se adapta melhor ao espaço de busca arquitetural e como cada um lida com o trade-off entre exploração e exploração nesse domínio.

4. Formulação Preliminar

4.1 Variáveis de Decisão

Cada solução (arquitetura candidata) é representada por um vetor de configurações com os seguintes componentes:

- $n_layers \in \{1, 2, 3, 4\}$ — número de camadas convolucionais

- $\text{filters}_i \in \{16, 32, 64, 128\}$ — número de filtros na i -ésima camada convolucional (para $i = 1, \dots, n_{\text{layers}}$)
- $\text{activation} \in \{\text{ReLU}, \text{LeakyReLU}\}$ — função de ativação aplicada em todas as camadas

A camada de classificação (fully connected + softmax com 10 saídas) é fixa para todas as arquiteturas, de modo que o espaço de busca se concentra exclusivamente nas camadas convolucionais.

4.2 Objetivos

O problema é formulado como multiobjetivo, com três funções a serem otimizadas simultaneamente pelo NSGA-II na fase de comparação multiobjetivo:

- f_1 : Maximizar acurácia de classificação no conjunto de teste do MNIST
- f_2 : Minimizar o número total de parâmetros treináveis da rede
- f_3 : Minimizar o tempo médio de inferência por lote (ms)

Na fase single-objective (AG e PBIL), será usada uma função escalarizada combinando f_1 e f_2 com pesos a serem definidos experimentalmente. O Optuna otimizará f_1 diretamente, com f_2 e f_3 como métricas de análise.

4.3 Restrições

- Número máximo de parâmetros: ≤ 500.000 (garantir viabilidade computacional em CPU)
- Acurácia mínima aceitável: $\geq 90\%$ no conjunto de teste (soluções abaixo são penalizadas)
- Tempo de treinamento por avaliação: limitado a 3 minutos por arquitetura candidata
- Espaço de busca restrito a arquiteturas feedforward sequenciais (sem skip connections)

5. Referências Iniciais

-
- [1] Elsken, T., Metzen, J. H., & Hutter, F. (2019). Neural Architecture Search: A Survey. *Journal of Machine Learning Research*, 20(55), 1–21.
 - [2] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. In *Proceedings of KDD 2019*.
 - [3] Baluja, S. (1994). Population-Based Incremental Learning: A Method for Integrating Genetic Search Based Function Optimization and Competitive Learning. Technical Report CMU-CS-94-163, Carnegie Mellon University.
 - [4] Deb, K., Pratap, A., Agarwal, S., & Meyarivan, T. (2002). A Fast and Elitist Multiobjective Genetic Algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, 6(2), 182–197.
 - [5] Real, E., Aggarwal, A., Huang, Y., & Le, Q. V. (2019). Regularized Evolution for Image Classifier Architecture Search. In *Proceedings of AAAI 2019*.
 - [6] LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278–2324.